PROJET BIG DATA · IPSSI

Sismicité mondiale, 2016–2025

Que révèlent dix ans de séismes sur leur répartition, leur profondeur et la loi de Gutenberg-Richter ?

Ilham KADRI – École IPSSI · HDFS, Delta Lake, Spark, Streamlit

LES DONNÉES

Le catalogue mondial des séismes de l’USGS

1 604 291
événements de 2016 à 2025

522
fichiers CSV, un par semaine

300 Mo
de données brutes

Une API gratuite, en CSV : date, position, profondeur, magnitude, type d’événement…

97,7 % de séismes. Le reste : tirs de carrière, explosions, et même **3 explosions nucléaires**.

LA DÉMARCHE

Une étape, un notebook, des preuves chiffrées

01
Infrastructure
HDFS, Spark et Delta dans Docker

02
Ingestion
API USGS, semaine par semaine

03
Dépôt HDFS
522 CSV, 2 copies de chaque

04
Bronze
Les données brutes en Delta

05
Silver
Nettoyage, rejets, MERGE

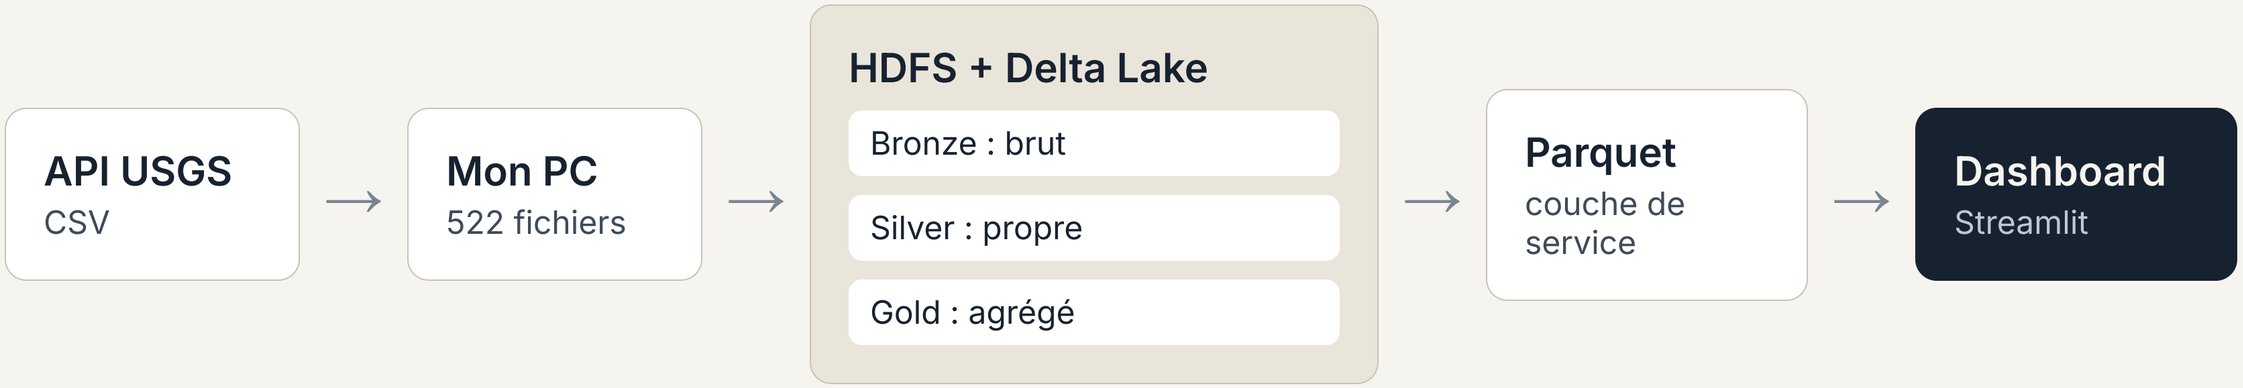
06
Gold
5 tables, une par graphique

07
IA
KMeans des zones sismiques

→
Dashboard
Streamlit et Plotly

L'ARCHITECTURE

Les données traversent un lakehouse sur HDFS



Spark fait tout le traitement
1 master, 2 workers ; le driver tourne dans Jupyter

Tout tourne dans Docker
9 conteneurs : HDFS (3), Spark (4), Jupyter, dashboard

QUALITÉ DES DONNÉES

Chaque ligne finit à un seul endroit

Lignes	Nombre
Reçues de l'API	1 604 291
Hors périmètre (pas des séismes)	37 170
Rejetées (magnitude vide)	615
Doublons	0
Gardées dans silver	**1 566 506**

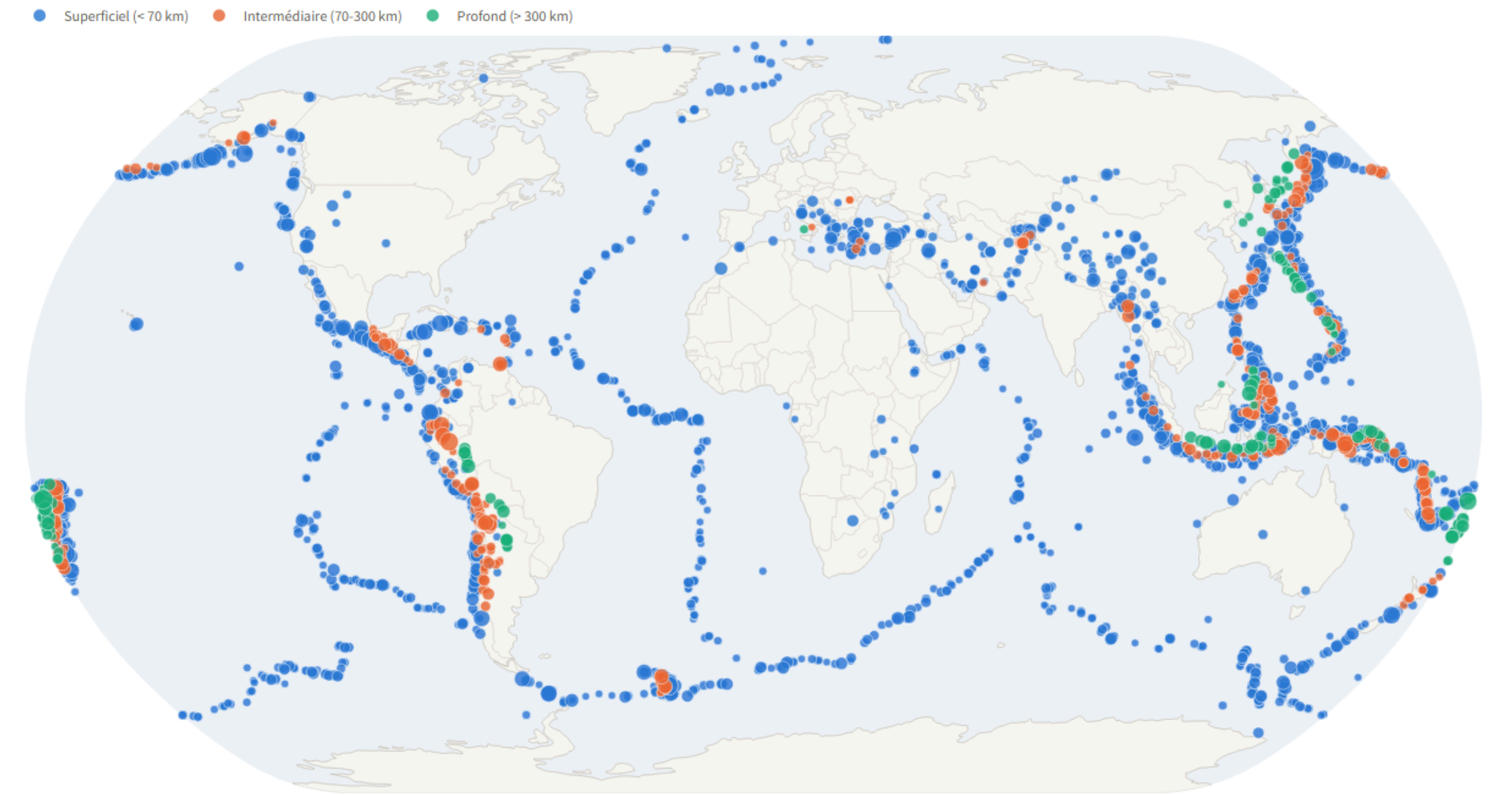
MON CHOIX

Je n'ai pas remplacé les magnitudes vides par la médiane.

La magnitude est ce que j'étudie : inventer une valeur aurait créé de faux séismes et faussé la loi de Gutenberg-Richter.

RÉSULTAT 1

Les séismes dessinent les frontières des plaques



74 362

séismes de magnitude 4,5 ou plus, environ 20 par jour

79 %

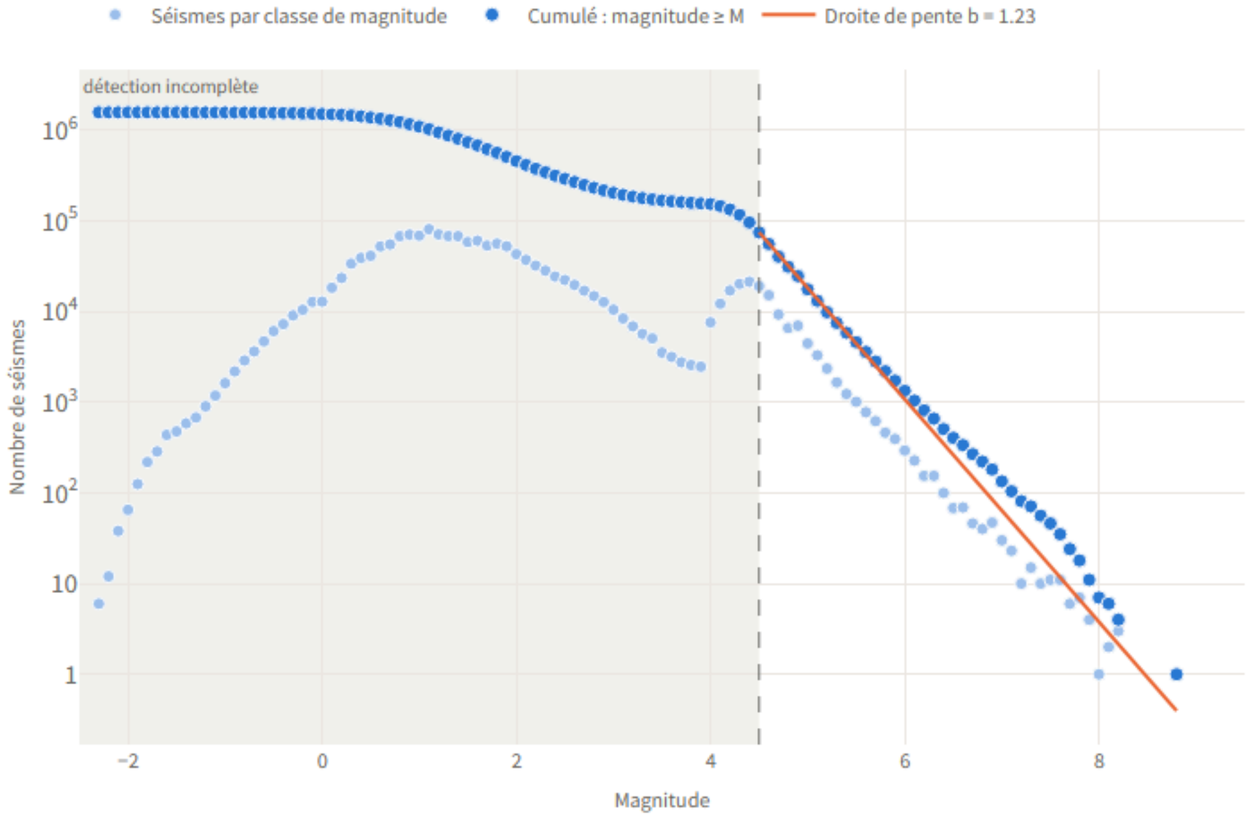
sont superficiels (moins de 70 km)

4,6 %

sont profonds (plus de 300 km), sous les zones de subduction

RÉSULTAT 2

La loi de Gutenberg-Richter est vérifiée



Valeur b mesurée

1,23

stable chaque année, de 1,20 à 1,27

À chaque magnitude en plus, environ **10 fois moins** de séismes.

Avant 4,5, la courbe s'écroule : les petits séismes sont mal détectés hors des États-Unis. D'où mon seuil Mc = 4,5.

RÉSULTAT 3 · L’ÉNERGIE

134 séismes, 86 % de l’énergie

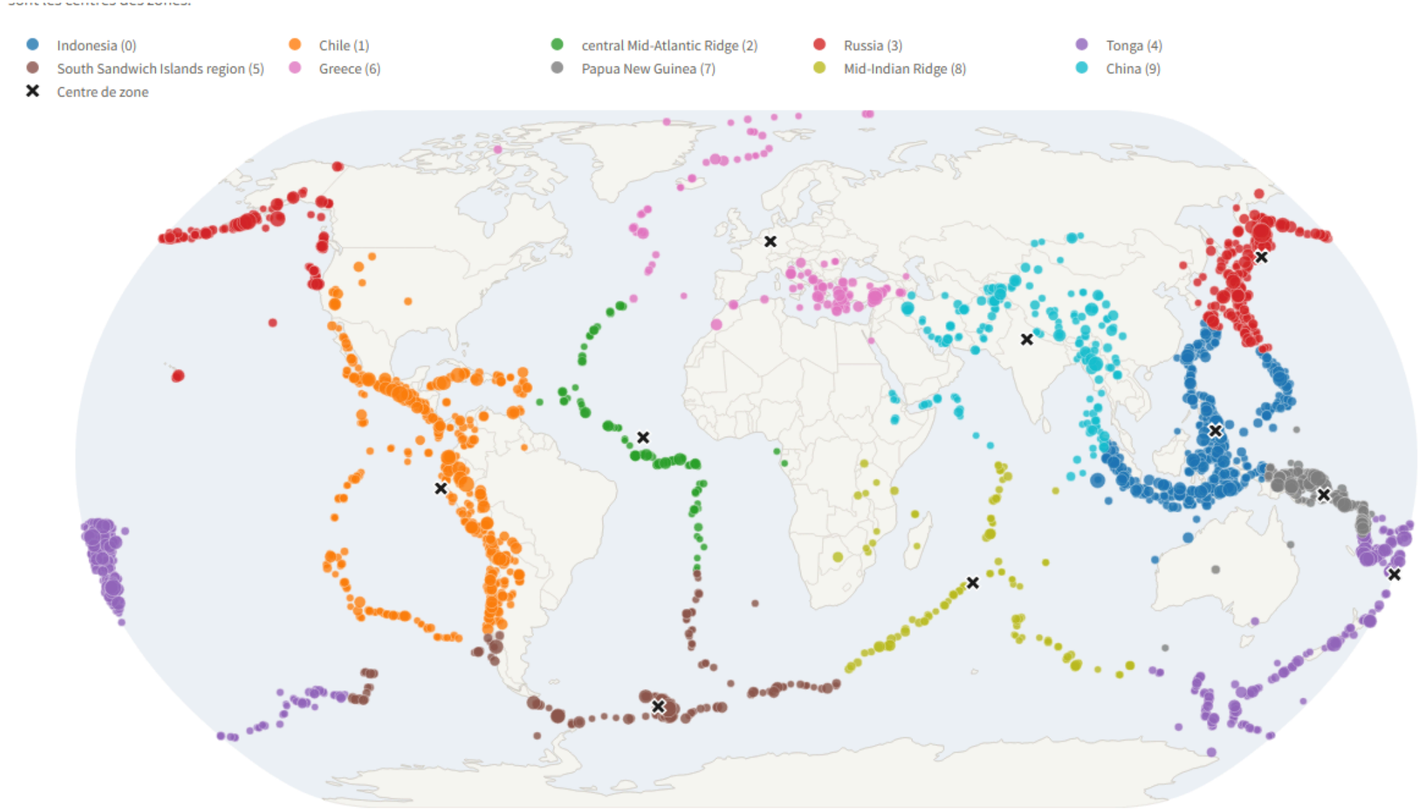
Les séismes de magnitude 7 ou plus ne sont que 0,18 % du total, mais ils libèrent presque toute l’énergie.

Kamtchatka, juillet 2025, magnitude 8,8 : **31 % de l’énergie** des dix ans à lui seul.

+1 de magnitude, c’est environ **32 fois plus d’énergie**.

IA · KMEANS (SPARK MLLIB)

Le KMeans retrouve seul les zones sismiques



10 zones

score silhouette 0,613 : bien séparées

18,1 %

de séismes profonds dans la zone Tonga, moins de 3 % ailleurs

Astuce : latitude et longitude converties en x, y, z sur une sphère, pour que 179° et −179° restent voisins.

DÉFIS

Ce qui m’a bloquée, et comment j’ai fait

Problème	Solution
L’API refuse plus de 20 000 séismes par requête	Téléchargement semaine par semaine
522 petits fichiers pour des blocs HDFS de 128 Mo	Regroupés en 4 fichiers Parquet en bronze
Delta refuse un MERGE si un id est en double	Dédoublonnage avant, on garde le plus récent
Un notebook resté ouvert gardait les cœurs du cluster	spark.stop() à la fin de chaque notebook
Des magnitudes à −9,99 (valeur « inconnue »)	Repérées dans le dashboard : règle à ajouter

BILAN

Une chaîne complète, vérifiée à chaque étape

Limites

- Tout tourne sur un seul PC
- Un seuil de 4,5 identique partout
- Une révision simulée pour tester le MERGE
- 300 Mo : la chaîne est surdimensionnée

Et ensuite

- Stockage objet (S3, MinIO) à la place de HDFS
- Airflow pour automatiser la chaîne
- Kafka pour suivre les séismes en temps réel
- Une règle pour les magnitudes impossibles

Merci ! Des questions ?