Projet Big Data : sismicité mondiale 2016-2025

Nov 12, 2026 · @il

1. Contexte et problématique

L'objectif du projet est de concevoir une architecture Big Data complète, de l'ingestion des données jusqu'à leur restitution dans un tableau de bord, et de justifier chaque choix technique.

J'ai choisi d'appliquer cette chaîne à la sismicité mondiale entre 2016 et 2025, avec la problématique suivante : que révèlent dix ans de séismes sur leur répartition géographique, leur profondeur et les lois statistiques qui les gouvernent ?

Le fil conducteur scientifique est la loi de Gutenberg-Richter, selon laquelle le nombre de séismes est divisé par environ 10 chaque fois que la magnitude augmente d'une unité. Cette décroissance est mesurée par la valeur b, proche de 1 à l'échelle mondiale. Mon objectif chiffré était de la recalculer à partir de mes propres données.

2. Jeu de données

J'ai utilisé le catalogue mondial des séismes de l'USGS (United States Geological Survey), accessible par une API publique qui renvoie les événements au format CSV. Chaque ligne décrit un événement : date, latitude, longitude, profondeur, magnitude, type d'événement, statut de révision, etc. (22 colonnes).

Ce jeu de données répondait bien aux attentes du sujet : il est volumineux, structuré, géolocalisé, et il permet de confronter les données à une loi physique connue.

Indicateur	Valeur
Période couverte	2016 à 2025
Fichiers téléchargés	522 (un par semaine)
Événements	1 604 291
Volume brut	environ 300 Mo
Part de séismes (type earthquake)	97,7 %

L'exploration a montré que le catalogue ne contient pas uniquement des séismes : on y trouve aussi des tirs de carrière (13 308), des séismes glaciaires, des explosions et même 3 explosions nucléaires. Ces événements ont été exclus du périmètre d'analyse.

3. Architecture

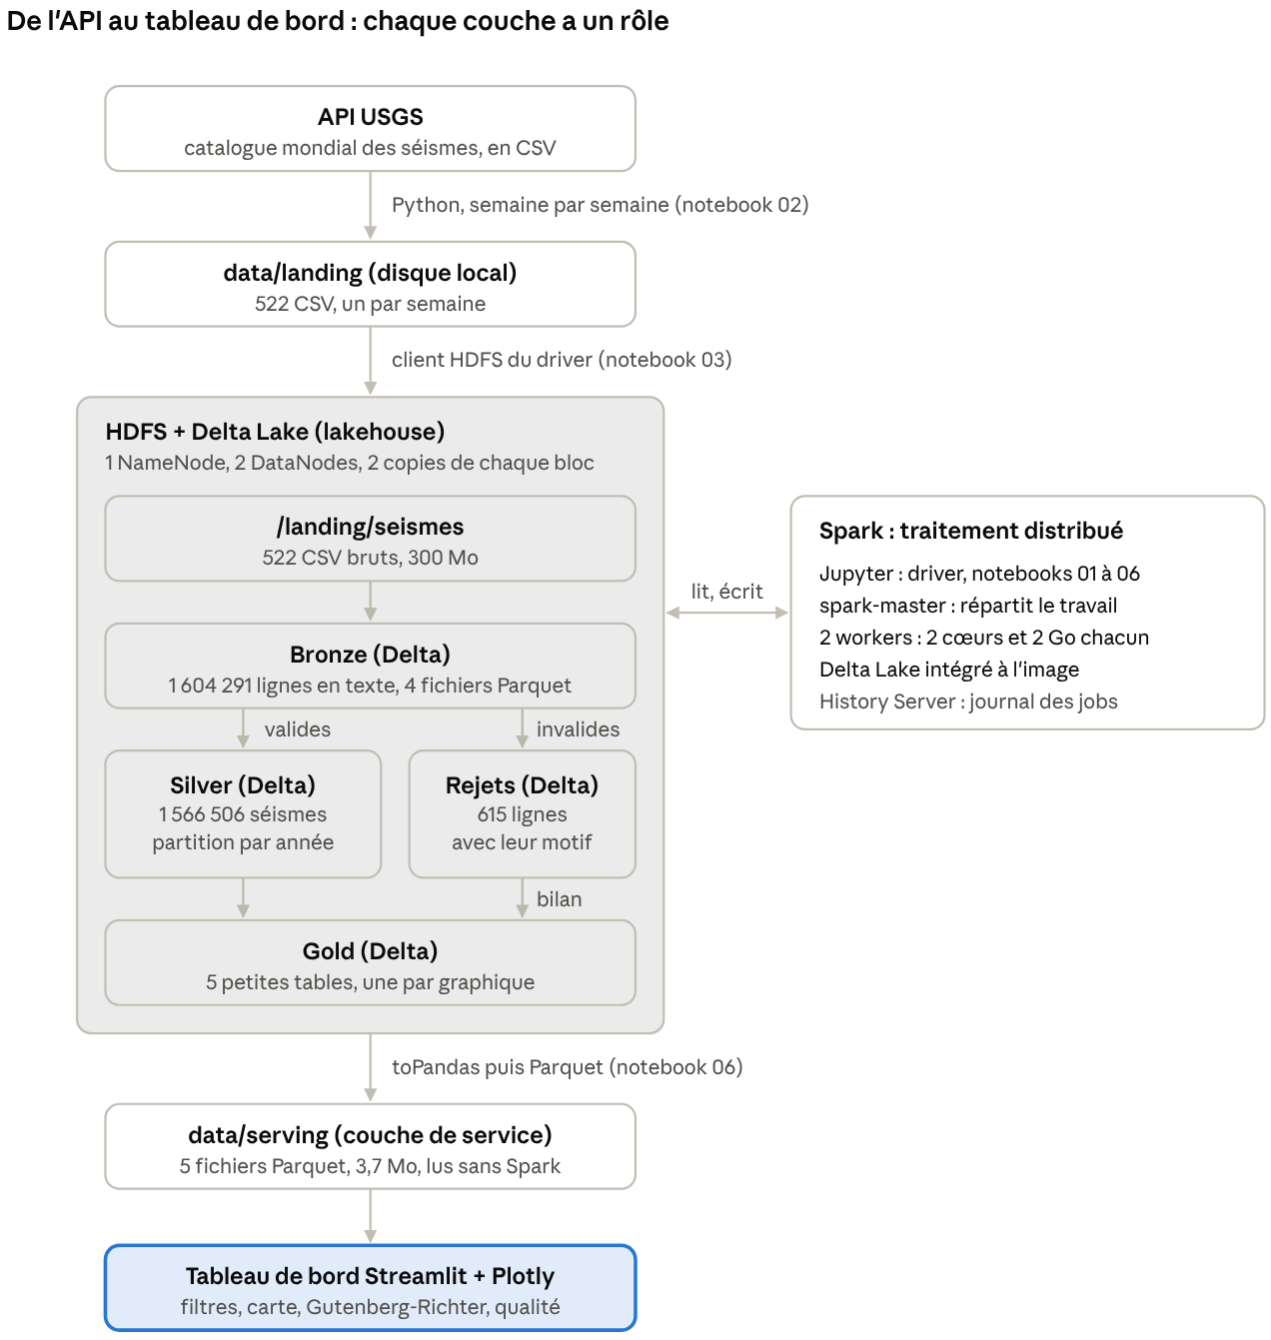


Figure 1 – architecture de la chaîne de données

L'architecture suit le modèle du lakehouse, avec trois couches successives (architecture médaillon) stockées dans HDFS au format Delta Lake :

- **bronze** : les données brutes, sans transformation, avec deux colonnes de traçabilité (date d'ingestion et fichier source) ;
- **silver** : les données nettoyées, typées, dédoublonnées et partitionnées par année ;
- **gold** : des tables agrégées, une par usage du tableau de bord.

Les tables gold étant petites, elles sont ensuite exportées en Parquet dans une couche de service locale. Le tableau de bord ne lit que cette couche : il ne dépend ni de Spark ni de HDFS, ce qui le rend plus rapide et découple la restitution du stockage principal.

L'ensemble tourne dans un seul Docker Compose de 9 conteneurs : HDFS (1 NameNode, 2 DataNodes), Spark (1 master, 2 workers, 1 History Server), Jupyter, qui héberge le driver Spark, et le tableau de bord Streamlit.

4. Mise en œuvre

J'ai organisé le traitement en un notebook par étape. Chacun se termine par des contrôles chiffrés qui valident l'étape avant de passer à la suivante.

1. **Infrastructure.** J'ai d'abord validé l'intégration Spark, HDFS et Delta Lake : écriture et relecture d'une table Delta sur HDFS, test d'un MERGE (1 ligne mise à jour, 1 ajoutée, aucun doublon) et historique des versions. Le calcul est bien réparti sur 4 cœurs (2 workers × 2 cœurs).
2. **Ingestion.** L'API refuse les requêtes de plus de 20 000 événements ; j'ai donc téléchargé les données semaine par semaine (environ 3 000 événements chacune). L'ingestion est relançable sans doublon : une semaine déjà présente est ignorée, et chaque fichier est écrit dans un fichier temporaire avant d'être renommé, pour ne jamais laisser de fichier incomplet.
3. **Dépôt dans HDFS.** Les 522 fichiers ont été copiés dans HDFS avec un facteur de réplication de 2. J'ai vérifié que le volume était identique à l'octet près (300 320 565 octets). Les fichiers faisant en moyenne 575 Ko pour des blocs de 128 Mo, j'ai identifié le problème classique des petits fichiers.
4. **Bronze.** Les CSV sont lus avec toutes les colonnes en texte, pour ne perdre aucune valeur, puis écrits en Delta. Le regroupement en 4 fichiers Parquet (131 Mo au total) règle le problème des petits fichiers. Contrôle : 1 604 291 lignes provenant des 522 fichiers.
5. **Silver.** Filtrage des séismes, typage des colonnes, application de quatre règles de qualité, dédoublonnage par identifiant, puis écriture partitionnée par année. Le MERGE a été testé en rechargeant une semaine contenant une révision simulée : 1 ligne modifiée, 0 ajoutée.

6. **Gold.** Cinq tables agrégées (évolution mensuelle, distribution des magnitudes, profondeur, carte, bilan qualité), chacune vérifiée par recoupement des totaux avec silver.
7. **IA.** Regroupement des séismes en zones par KMeans (section 8).
8. **Tableau de bord.** Application Streamlit et Plotly, avec des filtres (période, magnitude), des indicateurs, une carte et sept onglets d'analyse.

5. Choix techniques

Outil	Rôle dans la chaîne	Justification
HDFS	Stockage distribué	Fichiers découpés en blocs et répliqués ; pile Hadoop vue en cours
Delta Lake	Format des tables	Transactions, historique des versions, MERGE : un dossier de fichiers devient une vraie table
Apache Spark	Traitement	Calcul réparti sur les workers, client HDFS intégré, compatible Delta
Spark MLlib	IA	KMeans directement sur les données du cluster
Jupyter	Développement	Un notebook par étape, avec le code et ses preuves au même endroit
Parquet	Couche de service	Format colonnaire compact, lu directement par pandas
Streamlit et Plotly	Restitution	Tableau de bord interactif écrit entièrement en Python
Docker Compose	Infrastructure	Toute la plateforme démarre en une commande, de façon reproductible

J'ai aussi fait des choix de simplification pour tenir dans le temps imparti :

- un seuil d'analyse unique, magnitude 4,5, qui correspond à la magnitude de complétude mondiale (en dessous, les petits séismes ne sont pas détectés partout) ;
- pas d'ingestion incrémentale quotidienne : le MERGE est démontré en rechargeant une semaine déjà présente ;
- une orchestration par les notebooks numérotés plutôt que par un outil dédié comme Airflow.

Avec 300 Mo, le volume ne justifie pas à lui seul un cluster. L'intérêt de cette architecture est de pouvoir passer à l'échelle (catalogue complet, flux en temps réel) sans changer la logique des traitements.

6. Qualité des données

Chaque ligne finit à un seul endroit : silver, rejets ou hors périmètre

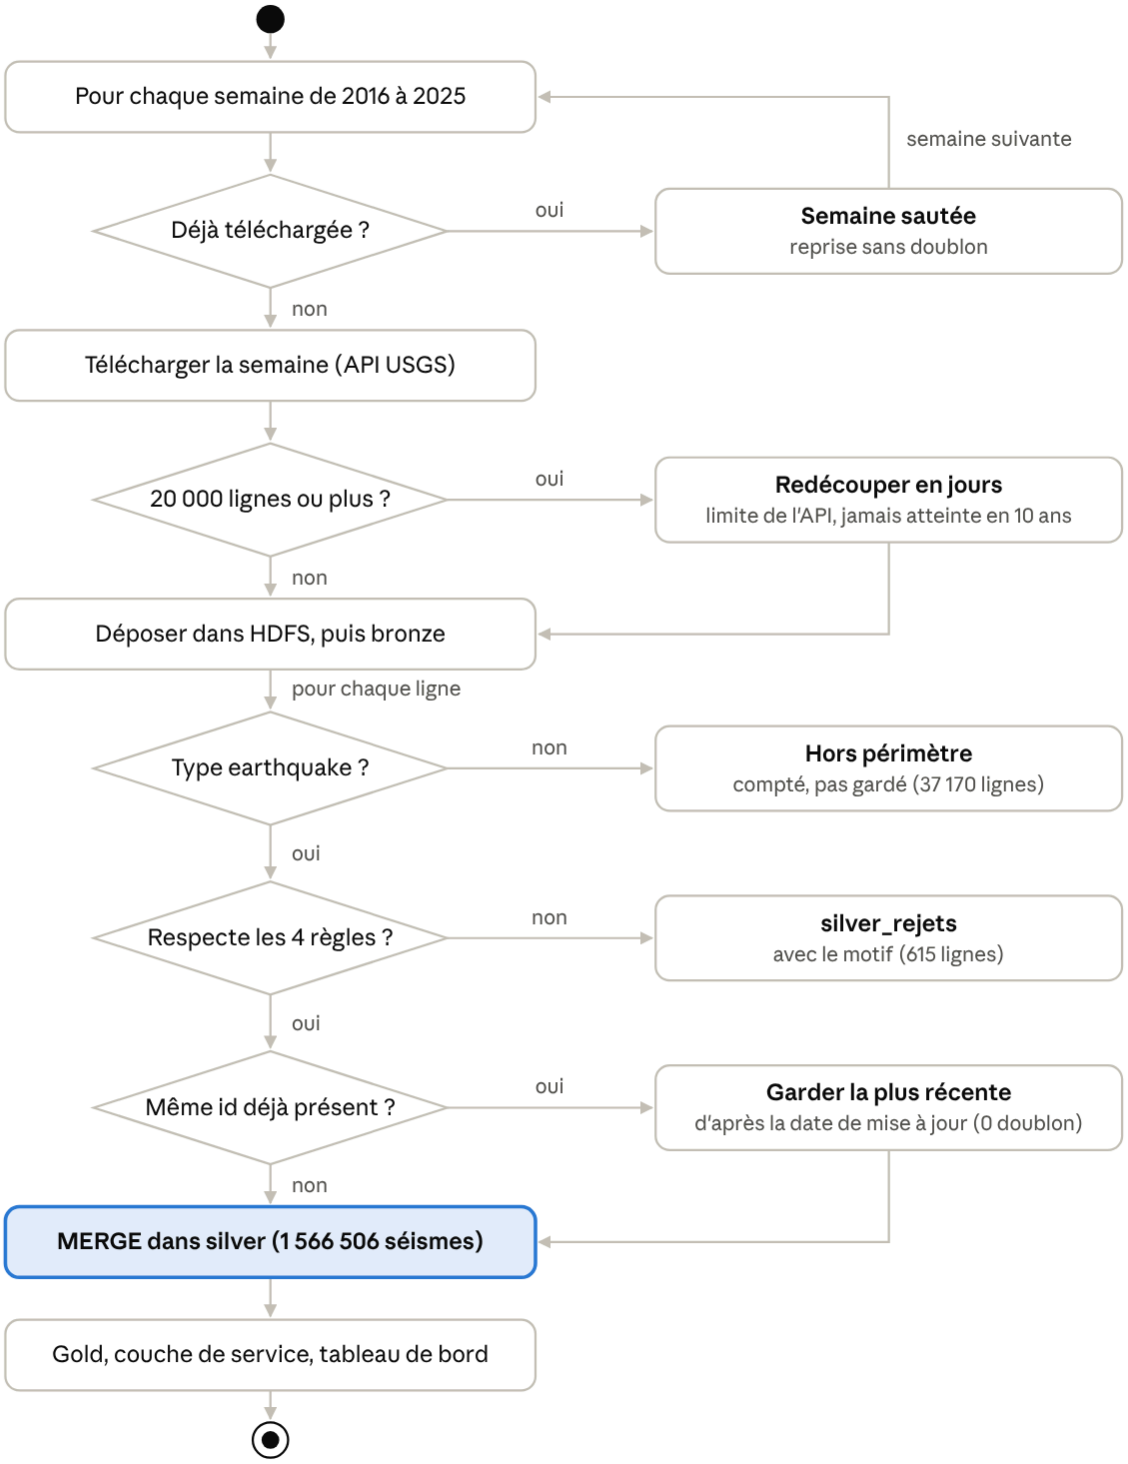


Figure 2 – diagramme d'activités de l'ingestion et du nettoyage

En silver, chaque séisme est contrôlé par quatre règles : identifiant présent, magnitude numérique, coordonnées valides et date lisible. Une ligne invalide n'est pas supprimée mais écrite dans une table de rejets avec son motif, ce qui permet de justifier chaque ligne écartée.

Catégorie	Lignes
Reçues de l'API	1 604 291
Hors périmètre (pas des séismes)	37 170
Rejetées (magnitude manquante)	615
Doublons	0
Conservées dans silver	1 566 506 (97,6 %)

Le bilan est complet : la somme des catégories redonne exactement le nombre de lignes reçues.

Pour les magnitudes manquantes, j'ai envisagé une imputation par la médiane, puis je l'ai écartée : la magnitude est la variable étudiée. Lui attribuer une valeur aurait créé des séismes fictifs concentrés sur une même magnitude, et biaisé la loi de Gutenberg-Richter. Avec 615 lignes sur 1,57 million, le rejet n'a aucun effet sur les résultats.

7. Résultats

Répartition géographique. Sur la période, on compte 74 362 séismes de magnitude 4,5 ou plus, soit environ 20 par jour. La carte montre qu'ils dessinent les frontières des plaques tectoniques, en particulier la ceinture de feu du Pacifique. Les régions les plus actives sont l'Indonésie (7 200 séismes), le Japon (5 595) et les Philippines (4 155).

Profondeur. 79,0 % des séismes sont superficiels (moins de 70 km), 16,4 % intermédiaires et 4,6 % profonds (plus de 300 km). La distribution remonte vers 600 km : ce sont les séismes des zones de subduction, comme celui des Fidji en 2018 (M 8,2 à 600 km).

Loi de Gutenberg-Richter. Sur une échelle logarithmique, le nombre de séismes par magnitude décroît de façon linéaire à partir de 4,5, ce qui confirme la loi. En dessous, la courbe chute, car la détection devient incomplète. J'ai estimé la valeur b avec l'estimateur d'Aki, b = log10(e) / (M moyenne − (Mc − 0,05)), avec Mc = 4,5. J'obtiens **b = 1,23**, stable d'une année à l'autre (de 1,20 à 1,27). La valeur est supérieure à la référence de 1 ; une explication probable est l'hétérogénéité des échelles de magnitude dans le catalogue (colonne magType).

Énergie. L'énergie libérée est multipliée par environ 32 à chaque unité de magnitude. Les 134 séismes de magnitude 7 ou plus ne représentent que 0,18 % des séismes, mais 86 % de l'énergie libérée. Le séisme du Kamtchatka de juillet 2025 (M 8,8) en représente à lui seul 31 %.

Évolution temporelle. L'activité tourne autour de 600 séismes par mois. Les pics correspondent aux grandes séquences de répliques : îles Kermadec (mars 2021), îles Sandwich du Sud (août 2021) et Kamtchatka (juillet 2025).

8. Intelligence artificielle : zones sismiques par KMeans

J'ai utilisé l'algorithme KMeans de Spark MLlib pour regrouper les 74 362 séismes de magnitude 4,5 ou plus en zones, sans lui fournir aucune information géologique. Il s'agit d'apprentissage non supervisé.

Un prétraitement était nécessaire. Utilisées telles quelles, latitude et longitude faussent les distances : les longitudes 179° et -179° sont voisines sur le globe, mais éloignées de 358° pour l'algorithme. J'ai donc projeté chaque séisme en coordonnées cartésiennes (x, y, z) sur une sphère, où la distance euclidienne correspond à la proximité réelle.

Le nombre de zones a été choisi en comparant k de 2 à 15 avec la méthode du coude et le score silhouette. Avec k = 10, le score silhouette est de 0,613, ce qui indique des zones bien séparées.

Zone (région principale)	Séismes	Part de séismes profonds
Indonésie	16 364	2,4 %
Tonga	14 902	18,1 %
Russie (Kamtchatka)	9 616	2,2 %
Chili	9 193	0,8 %
Papouasie-Nouvelle-Guinée	6 890	1,1 %
Chine	5 146	0,0 %
Îles Sandwich du Sud	4 958	0,0 %
Grèce	3 071	0,1 %
Dorsale de l'océan Indien	2 526	0,0 %
Dorsale médio-atlantique	1 696	0,0 %

Le modèle retrouve les grandes régions sismiques. Il isole aussi la zone Tonga, qui concentre presque tous les séismes profonds (18,1 % contre moins de 3 % ailleurs), signe d'une subduction profonde. Les deux zones de dorsales ont une profondeur moyenne de 10 km, typique des zones où les plaques s'écartent. La zone Tonga, qui traverse la longitude 180°, reste un seul groupe : cela valide la projection sur la sphère.

La principale limite vient de la nature du KMeans, qui forme des groupes compacts autour d'un centre et ne suit pas la forme allongée des frontières de plaques. La zone « Chili » regroupe ainsi toute la côte ouest américaine, du Mexique au Chili. Les zones sont enregistrées en gold et affichées dans un onglet dédié du tableau de bord.

9. Difficultés rencontrées

Difficulté	Solution
L'API limite les réponses à 20 000 événements	Téléchargement par semaine, avec un découpage par jour prévu en secours
Le client HDFS de Spark créait 3 copies au lieu de 2	Facteur de réplication fixé dans la configuration de Spark
522 petits fichiers face à des blocs de 128 Mo	Regroupement en 4 fichiers Parquet dès la couche bronze
Delta refuse un MERGE si un identifiant apparaît deux fois dans la source	Dédoublonnage préalable, en conservant la version la plus récente
Une session Spark restée ouverte bloquait les cœurs du cluster	Arrêt systématique de la session à la fin de chaque notebook
Des types d'événement écrits avec des casses différentes	Comparaison après passage en minuscules

10. Limites et perspectives

- **Cluster simulé** : tous les conteneurs partagent le même ordinateur. La réplication montre le mécanisme, pas une réelle tolérance aux pannes.
- **Seuil de complétude fixe** : Mc = 4,5 est une approximation mondiale, alors que la complétude réelle varie selon les régions et les années.
- **Valeurs sentinelles** : 32 séismes ont une magnitude de -9,99 ou -5, des valeurs utilisées par certains réseaux pour une magnitude inconnue. Elles n'affectent pas la valeur b (toutes sous 4,5), mais mes règles de qualité ne les détectent pas.
- **MERGE démontré sur une révision simulée**, faute d'ingestion incrémentale réelle.

Pistes d'amélioration : remplacer HDFS par un stockage objet (S3, MinIO) sans modifier les traitements ; orchestrer la chaîne avec Airflow et ajouter une ingestion quotidienne ; traiter le flux USGS en temps réel avec Kafka ; ajouter une règle sur les magnitudes impossibles ; tester un algorithme de regroupement par densité (DBSCAN), plus adapté à la forme des frontières de plaques.

Conclusion

J'ai mis en place une chaîne Big Data complète, de l'API USGS jusqu'au tableau de bord, en vérifiant à chaque étape qu'aucune ligne n'était perdue. Les résultats répondent à la problématique : les séismes se concentrent le long des frontières de plaques, en majorité à faible profondeur, et ils suivent la loi de Gutenberg-Richter avec une valeur b stable de 1,23. Le KMeans retrouve, sans aucune connaissance géologique, les grandes zones sismiques du globe.

Ce projet m'a surtout permis de comprendre le rôle de chaque couche d'une architecture lakehouse, et l'importance de contrôler la qualité des données avant d'en tirer des conclusions.

Sources : USGS Earthquake Catalog (ComCat) ; K. Aki (1965), « Maximum likelihood estimate of b in the formula log N = a − bM and its confidence limits », Bulletin of the Earthquake Research Institute, 43, p. 237-239.